

Sistemi odlučivanja u medicini
Univerzitet u Beogradu - Elektrotehnički fakultet

Projektni zadatak iz predmeta
13E053SOM - Sistemi odlučivanja u medicini

Elektrotehnički fakultet u Beogradu
školska 2025/26 godina



Profesor:
prof. dr. Marija Novčić

Studenti:
Rastko Lazarević 2023/0016
Đorđe Ristić 2023/0064

Beograd, jul 2026.

Contents

1 Uvod

- 1.1 Osnovne informacije o bazi
- 1.2 Opis problema

2 Analiza skupa podataka

- 2.1 Nedostajuće i nevalidne vrednosti
- 2.2 Ekstremne vrednosti (outliers)
- 2.3 Kodiranje kategorijskih obeležja

3 Selekcija obeležja

- 3.1 Informaciona dobit
- 3.2 Korelacija između izabranih obeležja
- 3.3 Raspodela uzoraka po klasama

4 Redukcija dimenzija

5 Testiranje hipoteza i parametarska klasifikacija

- 5.1 Provera separabilnosti
- 5.2 Linearni klasifikator na bazi željenog izlaza
- 5.3 Rezultati

6 Neparametarska klasifikacija

- 6.1 Optimizacija dubine stabla
- 6.2 Rezultati na test skupu
- 6.3 Interpretabilnost

7 Neuralne mreže

- 7.1 Tri arhitekture
- 7.2 Zaštita od preobučavanja
- 7.3 Rezultati na test skupu

8 Komparativna analiza

- 8.1 Diskusija

1. Uvod

Za izradu projektnog zadatka izabrana je baza podataka **Cardiovascular Disease Dataset** (izvor: Kaggle, autor sulianova), koja sadrži podatke o pacijentima sa ciljem predikcije prisustva kardiovaskularne bolesti.

1.1 Osnovne informacije o bazi

- **Broj uzoraka:** 70000 originalno, 69971 nakon uklanjanja nevalidnih vrednosti
- **Broj obeležja:** 13 (nakon predobrade i kodiranja kategorijskih promenljivih)
- **Tip obeležja:** kombinacija kontinualnih (starost, visina, težina, sistolni i dijas-tolni pritisak) i kategorijskih/binarnih obeležja (pol, holesterol, glukoza, pušenje, konzumacija alkohola, fizička aktivnost)
- **Broj klasa:** 2 (binarna klasifikacija - `cardio` = 0 ili 1)
- **Izlazna promenljiva:** `cardio` - prisustvo (1) ili odsustvo (0) kardiovaskularne bolesti

1.2 Opis problema

Predikcija kardiovaskularnih bolesti je od izuzetnog kliničkog značaja jer omogućava ranu identifikaciju pacijenata sa povišenim rizikom, čime se pruža šansa za pravovremenu prevenciju i drastično smanjenje stope smrtnosti. Sa medicinskog stanovišta, ključna obeležja za tačnu procenu rizika uključuju osnovne demografske i fiziološke faktore, kao što su starost pacijenta, vrednosti sistolnog i dijas-tolnog krvnog pritiska, kao i nivo holesterola u krvi. Pored njih, prisustvo komorbiditeta poput dijabetesa, indeks telesne mase (BMI) i životne navike kao što je pušenje, predstavljaju neizostavne kliničke indikatore opterećenja srca i krvnih sudova. Sveobuhvatna analiza ovih parametara omogućava zdravstvenim radnicima da primene personalizovane terapijske mere i time značajno unaprede dugoročne kliničke ishode kod obolelih.

2. Analiza skupa podataka

2.1 Nedostajuće i nevalidne vrednosti

U originalnom skupu podataka nije bilo nedostajućih (NaN) vrednosti, ali su uočene nevalidne vrednosti u obeležjima `ap_hi` (sistolni pritisak) i `ap_lo` (dijastolni pritisak) - konkretno, vrednosti manje ili jednake nuli, što je klinički nemoguće. Ove vrednosti su zamenjene sa NaN i uklonjene, što je rezultovalo gubitkom 29 uzoraka (0.04% skupa) - zanemarljivo u odnosu na ukupnu veličinu skupa.

2.2 Ekstremne vrednosti (outliers)

Za obradu ekstremnih vrednosti u kontinualnim obeležjima korišćen je IQR (Interquartile Range) pristup sa *clipping* strategijom - vrednosti van opsega $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$ su ograničene (clipped) na granične vrednosti opsega, umesto brisanja odgovarajućih uzoraka. Ovaj pristup je izabran kako bi se očuvao broj uzoraka u skupu podataka, uz istovremeno ublažavanje uticaja ekstremnih (verovatno pogrešno unetih) merenja.

2.3 Kodiranje kategorijskih obeležja

Kategorijska obeležja (`gender`, `cholesterol`, `gluc`) kodirana su metodom *One-Hot Encoding*. Obeležje `age` (izraženo u danima) je izostavljeno iz daljeg razmatranja jer predstavlja linearnu transformaciju već postojećeg obeležja `age_years` (izraženo u godinama), pa bi njegovo zadržavanje unelo nepotrebnu redundansu.

3. Selekcija obeležja

3.1 Informaciona dobit

Za svako od 13 raspoloživih obeležja izračunata je informaciona dobit (Information Gain) u odnosu na izlaznu klasu. Rezultati su prikazani u Tabeli 1.

Table 1: Informaciona dobit po obeležjima (sortirano opadajuće)

Obeležje	Informaciona dobit
ap_hi	0.168830
ap_lo	0.106189
age_years	0.044175
cholesterol_3	0.027792
weight	0.025528
cholesterol_2	0.004812
gluc_3	0.003585
gluc_2	0.002023
active	0.000915
height	0.000674
smoke	0.000174
gender_2	0.000048
alco	0.000040

Na osnovu dobijenih rezultata, obeležja sa najvećom informacionom dobiti su **ap_hi** (sistolni pritisak), **ap_lo** (dijastolni pritisak) i **age_years** (starost), što je u skladu sa medicinskim znanjem o faktorima rizika za kardiovaskularne bolesti. Odabrano je top 10 obeležja sa najvećom informacionom dobiti za dalju analizu.

3.2 Korelacija između izabranih obeležja

Međusobna korelacija između 10 izabranih obeležja izračunata je Pirsonovom metodom korelacije, prikazana na Slici 1.




Figure 1: Matrica korelacije izabranih obeležja

Raspodela vrednosti korelacionih koeficijenata (bez dijagonale) prikazana je na Slici 2, sa prosečnom apsolutnom korelacijom od 0,105 i maksimalnom od 0,727.




Figure 2: Raspodela vrednosti korelacionih koeficijenata

3.3 Raspodela uzoraka po klasama

Za dva obeležja sa najvećom korelacijom sa izlaznom klasom (ap_{high} i ap_{low}) prikazana je raspodela uzoraka po klasama na Slici 3.




Figure 3: Raspodela uzoraka po klasama za dva najinformativnija obeležja

4. Redukcija dimenzija

Primenjena je LDA (Linear Discriminant Analysis) na ceo skup od 13 obeležja u cilju redukcije dimenzija.

Bitna napomena: pošto je izlazna klasa `cardio` binarna (2 klase), LDA po definiciji može da proizvede najviše $(\text{broj_klasa} - 1) = 1$ diskriminantnu komponentu. Zbog toga je odgovor na pitanje o minimalnom broju dimenzija za postizanje kumulativne objašnjene varijanse preko 80% trivijalno uvek **1 dimenzija** - druge dimenzije fizički ne postoje kod binarne klasifikacije.

Dobijena kumulativna varijansa iznosila je 1.01471772 (napomena: usled numeričke osobine `shrinkage='auto'` procene kod `sklearn` implementacije, ova vrednost može neznatno odstupati od teorijske gornje granice od 1.0).




Figure 4: Kumulativna objašnjena varijansa LDA komponenti

5. Testiranje hipoteza i parametarska klasifikacija

5.1 Provera separabilnosti

Pošto je **cardio** binarna klasa, primenjen je parametarski klasifikator (grana zadatka za testiranje više hipoteza se odnosi isključivo na višeklasne probleme i ovde nije primenjena).

Separabilnost klasa na 1D LDA projekciji procenjena je preko Fisher-ovog diskriminacionog odnosa:

$$\text{Fisher ratio} = \frac{(m_0 - m_1)^2}{\sigma_0^2 + \sigma_1^2} = 0.617$$

Dobijena vrednost ukazuje na **umerenu separabilnost** klasa - dovoljnu da opravda upotrebu linearnog klasifikatora, ali sa očekivanim приметnim preklapanjem između klasa.




Figure 5: Raspodela klasa na LDA projekciji

5.2 Linearni klasifikator na bazi željenog izlaza

Na osnovu procenjene separabilnosti, primenjen je **linearni klasifikator na bazi željenog izlaza** nad 1D LDA projekcijom, treniran na trening skupu (80%) i evaluiran na nezavisnom test skupu (20%).

5.3 Rezultati

Table 2: Matrica konfuzije - linearni klasifikator

	Predikcija 0	Predikcija 1
Stvarno 0	5484	1517
Stvarno 1	2394	4600

Table 3: Metrike klasifikacije - linearni klasifikator

Metrika	Vrednost
Tačnost (accuracy)	72.10%
Preciznost (precision)	75.2%
Senzitivnost (sensitivity)	65.8%
Specifičnost (specificity)	78.3%

6. Neparametarska klasifikacija

Izabrana neparametarska metoda je **stablo odlučivanja**, primenjeno na celokupnom skupu od 13 obeležja.

6.1 Optimizacija dubine stabla

Optimalna maksimalna dubina stabla određena je 5-strukom krosvalidacijom na trening skupu, testiranjem dubina u opsegu 1-24.




Figure 6: Optimizacija dubine stabla odlučivanja krosvalidacijom

Dobijena optimalna dubina iznosi 5, sa prosečnom krosvalidacionom tačnošću od 73.23%.

6.2 Rezultati na test skupu

Table 4: Metrike klasifikacije - stablo odlučivanja

Metrika	Vrednost
Tačnost (accuracy)	72.8%
Preciznost (precision)	75.3%
Senzitivnost (sensitivity)	67.8%
Specifičnost (specificity)	77.8%




Figure 7: Matrica konfuzije - stablo odlučivanja

6.3 Interpretabilnost

Analiza važnosti obeležja (feature importance) pokazuje da su najznačajnija obeležja ap_{hi} , age_{years} i $cholesterol_3$. Ilustrativni prikaz stabla ograničene dubine (radi čitljivosti) prikazan je na Slici 8.

Ilustrativni prikaz stabla (dubina ograničena na 3 radi čitljivosti)




Figure 8: Ilustrativni prikaz stabla odlučivanja i važnost obeležja

7. Neuralne mreže

Za neuralne mreže korišćen je `MLPClassifier` iz biblioteke `scikit-learn`, na celokupnom skupu od 13 obeležja, sa istom podelom trening/test skupa kao kod stabla odlučivanja.

7.1 Tri arhitekture

Trenirane su tri arhitekture radi ilustracije uticaja veličine mreže:

- **Dobra struktura:** (16, 8) neurona u dva skrivena sloja
- **Premalo neurona:** (2,) - nedovoljan kapacitet (underfitting)
- **Previše neurona:** (256, 256, 256) - preterani kapacitet (rizik od preobučavanja)




Figure 9: Performansa tokom obučavanja - poređenje tri arhitekture

7.2 Zaštita od preobučavanja

Za arhitekturu sa previše neurona primenjene su dve mere zaštite od preobučavanja:

- **Rano zaustavljanje (early stopping):** deo trening skupa se izdvaja kao validacioni skup; obučavanje se prekida čim validaciona greška prestane da se poboljšava, sprečavajući mrežu da nastavi da uči šum specifičan za trening skup.
- **Regularizacija (L2):** kroz parametar α dodaje se kazna na velike vrednosti težina u funkciji greške, čime se sprečava prekomerno prilagođavanje mreže trening podacima.




Figure 10: Efekat zaštite od preobučavanja (arhitektura 256,256,256)

Razlika između trening i test tačnosti **bez** zaštite iznosila je 23.38 procentnih poena, dok je **sa** primenjenom zaštitom ta razlika smanjena na 1.25 procentnih poena, što potvrđuje efikasnost primenjenih mera.

7.3 Rezultati na test skupu

Table 5: Metrike klasifikacije - neuralne mreže

Arhitektura	Tačnost	Preciznost	Senzitivnost	Specifičnost
Dobra struktura (16,8)	72.8%	74.4%	69.5%	76.1%
Premalo neurona (2,)	72.2%	73.6%	69.0%	75.3%
Previše (256,256,256) + zaštita	72.9%	74.4%	69.7%	76.0%

8. Komparativna analiza

U Tabeli 6 prikazani su rezultati svih primenjenih metoda klasifikacije.

Table 6: Komparativni pregled svih primenjenih metoda klasifikacije

Metoda	Tačnost	Preciznost	Senzitivnost	Specifičnost
Parametarska (linearni klasifikator)	72.0%	75.2%	65.8%	78.3%
Neparametarska (stablo odlučivanja)	72.8%	75.3%	67.8%	77.7%
Neuralna mreža (dobra struktura)	72.8%	74.4%	69.5%	76.1%

8.1 Diskusija

Sve primenjene metode konvergiraju ka sličnoj tačnosti (72-73%), bez obzira na to da li je pristup linearan i dimenziono redukovan (parametarski), zasnovan na hijerarhijskoj podeli prostora obeležja (stablo odlučivanja), ili na nelinearnoj transformaciji kroz slojeve neurona (neuralna mreža). Ovo je jak indikator da je ograničavajući faktor **informativnost samih raspoloživih obeležja** (krvni pritisak, holesterol, starost, itd.), a ne izbor klasifikacionog pristupa - drugim rečima, dostignut je plafon performanse koji ovaj skup podataka može da ponudi za predikciju kardiovaskularne bolesti sa datim obeležjima.

Prednosti i nedostaci po metodi:

- **Parametarski (linearni klasifikator):** najjednostavniji i računski najbrži, ali ograničen pretpostavkom linearne granice odlučivanja; dodatno ograničen time što LDA za binarnu klasu dozvoljava redukciju na svega 1 dimenziju.
- **Neparametarski (stablo odlučivanja):** ne pretpostavlja oblik raspodele podataka, radi direktno nad svih 13 obeležja, lako je interpretabilan (jasna pravila odlučivanja, važnost obeležja) - rizik od preobučavanja je kontrolisan krosvalidacijom dubine.
- **Neuralna mreža:** najveći kapacitet i fleksibilnost za modelovanje nelinearnih zavisnosti, ali i najosetljivija na izbor arhitekture (dokazano kroz underfitting/overfitting demonstraciju) - zahteva pažljivo podešavanje i duže vreme obučavanja, uz nižu interpretabilnost u odnosu na stablo odlučivanja.